Java面试基础

基础篇

java的四个特点：面向对象编程，跨平台能力强，多线程，强类型语言。

1. 三大特征：封装，继承，多态（静态多态和动态多态）
2. 面向对象和面向过程的区别：面向过程使用函数来完成，面向对象通过各种类来完成不同的功能实现。
3. 类和对象的基本概念：类是对象的模板，对象是类的实例。
4. java中的8种基本数据类型。
5. 重载和重写的区别：重载是子类中同一个名称的方法根据不同参数实现不同的功能；重写是针对父类不同子类的相同方法。
6. hashCode知识点：hashCode相同，equal不一定相同，因为可能会发生冲突；hashcode不相同，equal一定不相同。通过这种方式减少HashSet的equal对比次数。
7. ==和equal的区别：==针对基础类型的时候比较值，针对引用类型的时候比较引用地址；equal比较对象的引用地址，需要在类中重写equal方法。**重写equal时首先使用==来判断两个对象的引用类型是否相同，在进行字段级别的比较。**
8. String，StringBuilder和StringBuffer之间的区别是什么?

   String不可变，StringBuilder和StringBuffer可变；String和StringBuffer（使用了线程锁）是线程安全的，StringBuilder是非线程安全的。

   使用场景：对字符串少量改动时使用String，大量改动是使用StringBuilder，使用到多线程的时候使用StringBuffer。
9. String为什么是final关键字修饰：安全，由于不会被继承，所以就不会被修改；string使用频率较高，直接使用final对类进行修饰省事。
10. super和this的异同：super调用父类的方法和变量名，this使用自身的构造方法和变量名；super和this必须放在构造方法的第一行 ，并且不能同时出现。

集合篇

1. ArrayList和LinkedList的联系和区别：两个都是线程不安全的；ArrayList使用Object数组存放数据，LinkedList使用双向链表存放数据，这就导致了数据的存放和访问的效率不一样。
2. HashMap的底层特点：在JDK7之前都是使用数组+链表的形式来对数据进行存储，这样如果发生哈希冲突的话会使得链表越来越长，查询效率变低；JDK8之后使用数组+链表+红黑树的形式来存储，当链表数据个数超过8个就使用红黑树来存储数据，提高查询效率。
3. HashMap为什么是线程不安全的：当有多个线程插入的元素出现碰撞的时候可能会出现覆盖数据问题。
4. HashMap如何实现线程安全？使用ConcurrentHashMap实现了线程安全。
5. HashMap底层实现

多线程

1. 并发和并行的区别
2. 进程和线程：进程是资源分配的单位；线程是调度和执行的最小单位。
3. 线程同步的方法：同步方法；同步代码块。
4. 线程池：核心线程池，最大线程池，队列和拒绝策略。

判断核心线程池是否已满，没满则创建一个新的工作线程来执行任务。

判断任务队列是否已满，没满则将新提交的任务添加在工作队列。

判断整个线程池是否已满，没满则创建一个新的工作线程来执行任务，已满则执行饱和（拒绝）策略。

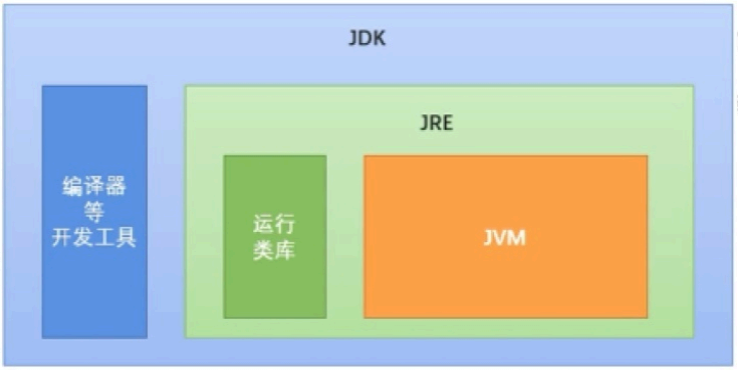
5. synchronized关键字；懒汉式和饿汉式的线程安全问题?

6. volatile关键字?

7. 线程死锁的原因（4），解决死锁的方式（3）。

JVM

1. JDK，JRE和JVM的区别。



数据库专题

1. SQL解析顺序。

```
(9)  SELECT
        (10) DISTINCT column,
        (6)  AGG FUNC(column or expression), ...
(1)  FROM left tab1
        (3)  JOIN right tab2
        (2)  ON tab1.column = tab2.column
(4)  WHERE constraint_expression
(5)  GROUP BY column
(7)  WITH CUBE ROLLUP
(8)  HAVING constraint_expression
(11) ORDER BY column ASC|DESC
(12) LIMIT count OFFSET count;
```

2. MYSQL中的日志文件：回滚日志，重做日志和二进制日志。

   回滚操作用于撤销没有写入到二进制日志中的事务。

   重做日志用于完成已经记录到二进制日志中的事务。

3. 三大范式的区别

4. 索引的作用是什么?

Hadoop系列

1. Hadoop的特点：高可靠性，高拓展性，高容错性，高效性；不适用低延迟数据访问，不能高效存储小文件，无法处理多用户同时写。
2. HDFS的定义：HDFS是一个高可靠，高容错的分布式文件存储系统，系统架构采用主从+主备的设计模式。Namenode，SecondaryNamenode，DataNode。
3. Hadoop的读流程：首先向Namenode获取数据所在的datanode地址，就近选取最近的datanode请求读取数据，datanode向客户端以packet为单位来进行数据传输。
4. Hadoop的写流程：首先向Namenode发起请求，判断是否存在父目录，NameNode同意写入之后；客户端再次发起请求询问写入的DataNode的位置，然后分别将各个Block以Packet为单位在各个Datanode之间建立起通信管道进行数据传输。
5. MapReduce是什么，优缺点：是一种采用分而治之思想的分布式计算框架，由Map和Reduce阶段组成，将大任务分成若干个小任务在不同机器上执行。易于编程，高拓展，高容错；不擅长流式计算，实时计算和DAG计算。
6. MapReduce的执行流程：Split，Map，Shuffle（环形缓冲区，快排和归并排序；归并排序），Reduce
7. MapReduce的排序：第一次是环形缓冲区超出阈值产生小文件进行排序；第二次是多个小文件之间进行归并排序；第三次是Reduce得到多个文件后进行归并排序。
8. 排序的作用：Reduce端需要对相同的key进行规约操作，排序可以提高找到相同key的时间，提高效率。
9. Yarn是什么：是hadoop的资源管理模块，采用主从的总体架构，由ResourceManager，ApplicationMaster，NodeManager和Container组成。
10. Yarn的资源调度器：先进先出，容量调度器，公平调度器。

Hive基础和HQL

1. 数据仓库和传统数据库的区别：使用场景，数据特征，模型设计，性能侧重，拓展方式。
2. Hive的体系架构和执行流程：分为客户端（CLI和Web GUI）和服务端（Driver-Compiler,Optimizer和Executor，MetaStore）。

   先调用Driver进行语法解析生成语法树；检查语法树是否存在语法问题，生成逻辑执行计划；编译器通过元数据信息来优化逻辑执行计划；生成物理执行计划转化为MapReduce任务；执行物理执行计划返回结果。
3. HQL转化为MapReduce的过程：生成AST树，检查AST树的语法，生成逻辑执行计划，生成物理执行计划，将物理执行计划提交到Hadoop执行。
4. Spark比MR快的原因：
   - Spark的磁盘IO次数少：每个MR任务只有一次shuffle过程，每次结束必须进行落盘操作；Spark任务可以包含多个Shuffle过程，只需要在最后进行落盘操作即可。
   - Spark的shuffle添加了Bypass机制，只在特定场景进行排序。
   - Spark支持对多次用到的数据进行缓存，操作。
   - MR是进程级别的任务，Spark是线程级别的任务；线程之间可以共享资源，无需多次申请资源。
5. hive读文件：先调用InputFormat，返回一条条键值对，然后使用SerDe的deserializer来将value根据分隔符切分成不同的字段。

6. hive写文件：先调用SerDe的Serializer对行进行序列化，再使用OutputFormat写入到HDFS中。
7. hive on spark和spark on hive的区别：
    - Hive on Spark是hive负责存储和sql优化，Spark来执行。
    - Spark on Hive是Hive负责存储，Spark负责优化和执行。
8. 内部表和外部表的区别，使用场景：在企业中90%使用的都是内部表。正常建表建立的就是内部表，外部表使用externel来修饰；内部表删除表之后元数据信息也一起删除，外部表删除表之后数据仍然保留。
9. 分区和分桶的区别：分区是将表分成多个文件夹，能够提高数据查询的效率，减少扫描量；分桶是根据表中某列的字段哈希划分成多个桶。
10. 静态分区和动态分区的区别：插入数据时静态分区需要手动指定分区，不容易出错；动态分区根据字段自动生成分区，可能会产生多个分区。
11. 新增字段时需要注意什么：restrict默认方式，添加字段之后不会更新元数据；cascade会修改元数据。
12. 行式存储和列式存储的区别，常见的存储格式有哪些：行式存储适用于插入和删除较频繁的场景，比如OLTP事务；列式存储（先划分行，在按照列进行存储）适用OLAP场景，同时将相同类型的数据一起存储可以获得较大的压缩比。
13. 常见的压缩格式：lzo，snappy，zstd。
14. with as可以提高执行效率吗：当多次用到临时表的时候可以提高效率，但是要配置参数，将临时表物化。
15. join的MR实现过程：分为common join和map join，common join以关联的字段作为key，其他字段作为value参与MapReduce任务；map join直接小表关联大表，在内存中实现。
16. 谓词下推：主表放入where中，从表的筛选放入on中。
17. 窗口函数一定会产生shuffle吗：大部分情况下都会产生shuffle，尤其是使用partition by之后；不会产生shuffle的情况，如max() over()。
18. 解析json函数：get_json_object(……，'$.{字段名}')和json_tuple(……，{字段名}, {字段名}) as ().
19. UDF函数的开发：继承UDF类，重写evaluate方法；打包到集群上；在hive命令行中添加函数。
20. map的个数和reduce的个数怎么得到的：map个数=文件总大小/每个map处理量（一般为block大小）；reduce同样通过计算推断出reduce的个数，不过可以手动指定每次任务处理的最大reduce个数。
21. 小文件问题：在一个任务中的最后会检查job输出的平均文件大小是否小于hive.merge.smallfiles.avgsize的大小，如果小于，则会产生map-only任务，此时会将多个小文件根据mapred.min.split.size.per.rack的大小进行合并，从而达到合并的效果。对于存量小文件直接insert overwriter即可。
22. group by的优化：负载均衡和map端聚合。

Hive优化

可以从

spark

1. spark的定义：spark是一种基于内存的快速、通用、可拓展的大数据计算引擎，是基于MR算法的分布式计算，具有MR的优点；但是比MR执行速度快，减少落盘操作。
2. spark和Hadoop的区别：spark基于内存进行计算，落盘次数少；spark使用DAG图，可以优化执行顺序，灵活调度资源；spark适用于实时数据处理，高计算速度的场景。
3. spark的集群运行架构：Master，Driver，Worker，Executor。
4. spark的作业执行流程：创建sparkcontext，申请资源；分配资源；创建task；sparkcontext生成DAG图，根据DAG图来划分若干个Stage，其中每个stage包含若干个task，将task交给executor执行。
5. spark on yarn中的yarn-client和yarn-cluster的区别是什么：on client是在本地创建driver进程，而cluster是在远程创建一个driver进程，一个适合调试，一个用于实际生产。
6. RDD的特性：弹性，分布式，延迟计算。
7. RDD的五大属性：分区列表，计算函数，依赖关系，分区器，首选位置。
8. 如何理解RDD的弹性：自动进行内存和磁盘的存储切换；血缘关系可溯源；task自动重试；checkpoint和persist。
9. 宽窄依赖：父子关系一对一和多对一，宽依赖会产生Shuffle，同时也是stage划分的标志。
10. Job，stage，task和executor之间的关系：一个job对应多个stage（是否产生宽依赖），一个stage由多个task组成（分区个数），executor执行具体的task。
11. cache和checkpoint的区别：cache是存储在内存中的，底层调用的是persist，不会截取血缘关系；checkpoint是存储在HDFS中，会截断血缘关系，会重新启动一个job，可以作为后续RDD的源头。建议checkpoint之前使用cache，避免产生新的job。
12. 广播变量：存在于executor中的内存中，如果一个executor有多个task，可以共享广播变量；是只读变量；由blockmanager管理，如果blockmanager没有则从driver端读取缓存到BM中。
13. 简单讲一下spark的shuffle：spark的shuffle分为shuffle write和shuffle read，其中shuffle write是指executor将执行好的结果放入到BM中，然后上报到Driver；下一个stage会进行shuffle read，从BM中读取数据信息。
14. shuffle的中间过程：shuffle中间过程会产生data文件和index文件，其中map端对分区中的数据进行计算生成data和index文件，然后reduce端通过index得知需要的data数据在哪。

RDD相关算子：

1. transformer算子和transaction算子：返回值类型和触发时间。tansformer算子是存储对RDD的操作，当遇到action算子的时候才会触发执行。

数仓理论

1. 什么是数据仓库：数据仓库是一个面向主题，集成的，相对稳定的，能够反映历史趋势变化的数据集合，用来支持企业或组织的管理决策。
2. 数据仓库的好处：集成和统一分散的数据源，能够支持复杂的分析需求（统一的数据视图）；能够反映历史变化趋势；能够降低存储的成本。
3. 数据仓库的专业名词：数据源，业务过程，度量/维度，事实表，维度表，原子指标，派生指标（原子指标+修饰词+时间周期），衍生指标（通过多种指标计算得到），数据模型。

4. 数据库和数据仓库的区别：OLAP和OLTP的解释，一个注重分析，一个注重效率；数据仓库不是为了取代数据库，而是数据库发展到一定程度之后的产物，目的是集成不同数据库中的数据，并且加上维度来进行统计汇总分析。

   区别可以从：设计目的（OLAP和OLTP）；数据特性（当前数据和历史数据）；数据处理方式（增删查改和ETL）；应用场景（Web应用和报表开发）；用户群体（业务开发人员和数据分析师、业务方）

5. Immon（数据驱动）和Kimball（业务驱动）两种数仓架构的特点：设计思路；建模方式；适用公司；开发周期
6. 指标和标签的区别：指标是客观存在的，以量化为目的，比如信贷项目中的授信总金额；标签是人为定义的，比如授信总金额多的称之为大客户。
7. 一致性事实和一致性维度的含义：指在不同的数据集市中有相同的事实结果和维度定义。
8. 事实表和维度表之间的关系；实体表和事实表/维度表的关系。
9. 数据仓库和数据集市的区别：数据集市是数据仓库的一个子集。（面向对象，数据量，处理速度，数据粒度，设计复杂度）
10. 数据分层的作用 5：清晰的血缘关系；降低成本，减少重复开发；提高数据质量和一致性；屏蔽原始数据的影响；简化开发和维护（拆分的思想让我们只需要对一个部分处理）
11. ODS，DWD，DWS，ADS分别的作用是什么。
12. 层次调用的规范：不能跨层调用；ADS不能相互调用；任务的深度不能过大；一个任务只允许产生一个表。
13. 集市层和公共层的区别
14. 公共层（dwd，dws，dim）和集市层（ads）的区别和联系
15. 数仓建模的目的和意义：先回答数仓的定义，降本增效，改善质量。
16. 数仓建模的方法：范式建模（能够减少数据冗余，适合OLTP，不适合查询）和维度建模（通过冗余数据来提高查询效率，存储成本大，面临一致性的问题）
17. 维度建模的过程：四个步骤，结合具体的项目来回答。
18. 星形模型，雪花模型和星座模型的区别和优缺点。
19. 三范式之间的区别：第一范式原子不可分；第二范式非主键不能部分依赖主键；第三范式非主键之间不能存在依赖。
20. 维度建模和范式建模的优缺点：范式建模同一份数据只存在一个地方，有限解决了一致性问题，但是查询起来效率低；维度建模通过冗余数据来达到提高查询效率，但是数据存储量大，同时需要解决一致性问题。
21. 三种不同的数据模型：实体关系（ER）模型，维度数据模型，Data vault模型。
22. 总线矩阵的作用：避免重复开发，指导分层建设，支持跨主题域分析。
23. 宽表的好处：提高查询性能；提高开发效率，开发人员可以使用更少的SQL完成工作；能够有效解决口径不一致的现象。
24. 宽表的理解和设计
25. 宽表的局限性：（生产时）性能较差，涉及多张表；稳定性较差；开发难度大（逻辑复杂）；拓展性差（业务方需求有关）
26. 怎么评价一个模型的好坏
27. 事实表的构成，事实表的类型和区别：（业务信息，度量，外键）；事务事实表，周期快照，累计快照

	事务事实表	周期快照事实表	累积快照事实表
时间/时期	时间	时期	时期（较短）
粒度	基本事件	时间周期	业务周期
加载方式	新增	新增	新增+修改
时间维	操作日期	期末时点	多个操作完成日期
例子	订单支付流水	每日账户余额/常见的按日的汇总表	物流包裹状态跟踪

28. 构建模型应该遵守哪些原则：高内聚低耦合；核心模型和拓展模型分离；公共逻辑下沉；指标命名清晰，一致
29. 维度退化和维度下沉的区别：维度退化不保留维度表，维度下沉保留维度表。
30. 维度表的两种类型：扁平维度表和雪花维度表。
31. 如何保证指标一致性：工具和平台支持；组织管理
32. 指标管理遇到的问题：同名不同义，同义不同名，口径不清晰，命名不规范。
33. 数据质量包括哪些部分：完整性，准确性，一致性，及时性
34. 怎么做到保证数据质量：数据量检测，空值检测，重复值检测。